

Project Hawkeye

Realisatiedocument

Stijn De Beuckeleer

Student Bachelor in de Toegepaste Informatica – Applicatieontwikkeling

Algorhythm Group (Cronos)

Inhoudsopgave

1. INLEIDING	5
2. ANALYSE	6
2.1. Databronnen	6
2.2. Technologiekeuzes	6
2.3. Werkwijze en tooling	7
2.4. Voorbereidende trainingen	7
3. DATA-ARCHITECTUUR	8
3.1. Medallion-architectuur	8
3.2. Dimensioneel datamodel	8
3.3. Semantic model	9
4. DATA ENGINEERING	11
4.1. Ingestie	11
4.2. Transformaties	12
4.3. Orchestratie	13
4.4. Datakwaliteit	13
5. DASHBOARDS	15
5.1. Ontwerp	15
5.2. Home dashboard	15
5.3. HR-rapport	16
5.4. Operations-rapport	18
5.5. Fleet-rapport	22
6. ITERATIE 2: SALESFORCE	23
6.1. Verkenning	23
6.2. Pipeline	23
6.3. Klantenmapping	23
6.4. Resultaat en overdracht	24
7. BESLUIT	24
7.1. Terugblik	24
7.2. Evaluatie tegen doelstellingen	25
7.3. Geleerde lessen	25
7.4. Toekomst en aanbevelingen	26
8. LITERATUURLIJST	27
9. BIJLAGEN	28
9.1. Bijlage A: Sterschema	29
9.2. Bijlage B: DAX-catalogus	30
9.3. Bijlage C: Detailed Design Document	30
9.4. Bijlage D: Business glossary	30

9.5. Bijlage E: Pipelinediagram	31
9.6. Bijlage F: Verklarende woordenlijst	32

Realisatiedocument

Student	Stijn De Beuckeleer
Opleiding	Bachelor in de Toegepaste Informatica
Academiejaar	2025-2026
Bedrijf	Algorhythm Group (Cronos)
Stagementor	Evelien De Keersmaecker

1. Inleiding

Algorhythm Group is een data-adviesbureau binnen de Cronos Groep met meer dan 50 consultants, verdeeld over vier gespecialiseerde entiteiten: Bright Dots (visualisatie), togaether (architectuur en engineering), Common Sense AI (kunstmatige intelligentie) en Georhythm (geodata). De organisatie beschikt over medewerkerdata in meerdere systemen: CronosCentral voor HR-gegevens en contracten, TIA voor urenregistratie, Salesforce voor klantrelaties en diverse andere bronsystemen voor loondata en projectbeheer. Door deze versnippering ontbreekt een geïntegreerd overzicht dat management, HR en operationele teams in staat stelt om gefundeerde beslissingen te nemen over personeelsbezetting, capaciteitsplanning en consultantprestaties.

Project Hawkeye heeft als doel deze datasilo's te doorbreken door een centraal dataplatform te bouwen in Microsoft Fabric, gekoppeld aan interactieve Power BI dashboards. Het project bouwt voort op meerdere eerdere pogingen door zowel Algorhythm-medewerkers als voorgaande stagiairs, die onder de naam Hawkeye de databronnen en stakeholder-requirements hebben geïnventariseerd maar niet tot een volledig werkende implementatie zijn gekomen. Deze stage neemt die analyse als vertrekpunt en richt zich op de technische realisatie.

In het projectplan is een iteratieve aanpak vastgelegd: elke iteratie voegt een set databronnen toe en doorloopt de volledige cyclus van analyse via data engineering tot visualisatie. Iteratie 1, de kern van dit realisatiedocument, integreert CronosCentral en TIA en levert dashboards op voor HR, Operations en Fleet, met een centrale landingspagina als startpunt. In de laatste weken van de stage is daarnaast iteratie 2 opgestart: de integratie van Salesforce als derde bronsysteem. Dit fundament is beschreven in hoofdstuk 6.

Dit document beschrijft achtereenvolgens de analyse en technologiekeuzes (hoofdstuk 2), de data-architectuur met het lakehouse en dimensioneel datamodel (hoofdstuk 3), de data engineering met pipelines en transformaties (hoofdstuk 4), de Power BI dashboards (hoofdstuk 5), de opgestarte Salesforce-integratie (hoofdstuk 6) en een evaluatie van het resultaat tegen de oorspronkelijke doelstellingen (hoofdstuk 7). Een verklarende woordenlijst van technische termen is opgenomen als Bijlage F.

2. Analyse

De analysefase had twee doelen: enerzijds de beschikbare data in kaart brengen en anderzijds de technologiekeuzes onderbouwen. Dit hoofdstuk beschrijft beide. Alle aantallen en schermafbeeldingen in dit document zijn gebaseerd op de data per april 2026, tenzij anders vermeld. April 2026 is gekozen als referentiepunt omdat het de meest recente volledige maand is op het moment van schrijven en alle databronnen op dat moment actueel en volledig gevuld waren.

2.1. Databronnen

De requirements voor Hawkeye zijn vastgelegd in vijf Business Requirements Documents (BRDs), opgesteld door stakeholders in eerdere projectfases.

Na analyse van deze BRDs zijn 149 individuele requirements geïdentificeerd, verdeeld over de domeinen HR, Operations, Sales, Klanten en Financieel. Om te bepalen welke requirements in iteratie 1 haalbaar zijn, moest eerst worden onderzocht welke data via API beschikbaar is.

Voor de twee primaire bronsystemen, CronosCentral en TIA, is een geautomatiseerde API-verkenning uitgevoerd. Hiervoor is een Python-tool gebouwd die achtereenvolgens het GraphQL-schema introspecteert (voor CronosCentral) of REST-endpoints inventariseert (voor TIA), de beschikbare datasets ophaalt, en per dataset een kwaliteitsprofiel opstelt met veldtypes, volledigheid, uniekheid en waardebereik.

CronosCentral is het HR-systeem van de Cronos Groep, ontsloten via een GraphQL API met Azure AD-authenticatie. Het systeem bevat vijf bruikbare entiteiten: **VEmployee** (161 records, waarvan 31 actief), **VFreelancer** (256 records, 19 actief), **VPerson** (samenvoeging van werknemers en freelancers), **Company** (4 Algorhythm-entiteiten) en **Car** (34 voertuigen).

TIA is het urenregistratiesysteem, ontsloten via een REST API met OAuth2. De belangrijkste datasets zijn Timesheets (145.980 uurregistraties over 11+ jaar), TimesheetCodes (circa 1.400 projectcodes over alle jaren), Users (55 gebruikers verdeeld over vijf entiteiten) en Reports/actuals (eindklantdata).

De verkenning bracht ook lacunes aan het licht. Contractregimes (voltijds/deeltijds), skills en loondata zijn niet beschikbaar in de twee bronsystemen van iteratie 1, de eerste projectfase waarin CronosCentral en TIA worden geïntegreerd. Deze velden zijn mogelijk pas beschikbaar wanneer aanvullende bronsystemen worden geïntegreerd in latere iteraties.

2.2. Technologiekeuzes

De technologiystack stond voor aanvang van de stage vast: Microsoft Fabric als dataplatform en Power BI voor visualisatie. Deze keuze werd niet door de student gemaakt, maar was een gegeven vanuit Algorhythm. Het bedrijf beschikt over Fabric-licenties via de Cronos Groep, het team heeft expertise in het platform, en de interne richtlijnen (togaether best practices) zijn volledig op Fabric afgestemd. Voor dit stageproject is het werken binnen de bestaande infrastructuur ook de logische keuze.

Fabric is een goed passend platform voor dit project. Het combineert data-opslag (lakehouse), data engineering (Spark-notebooks), orkestratie (pipelines) en visualisatie (Power BI) in één geïntegreerde omgeving.

Power BI wordt gebruikt binnen Algorhythm en sluit naadloos aan op het Fabric-lakehouse. Tableau en Qlik Sense zijn volwaardige alternatieven, maar zouden een aparte connectielaag vereisen.

De ETL-notebooks zijn geschreven in Python met PySpark, de standaard runtime in Fabric-notebooks. Voor de huidige datavolumes (tienduizenden rijen) zou Pandas volstaan, maar PySpark is een gangbare keuze binnen togaether en schaal goed wanneer er in latere iteraties grotere datasets worden toegevoegd.

2.3. Werkwijze en tooling

Naast het Fabric/Power BI-platform zijn twee tools bepalend geweest voor de dagelijkse werkwijze: Obsidian en Claude Code.

Obsidian is een markdown-gebaseerde kennisbeheertool die als centraal projectdossier heeft gefungeerd. Alle documentatie, sessielogs, weeklogs, analysedocumenten en werknotities zijn bijgehouden in een gestructureerde vault met onderlinge verwijzingen. Over de volledige stageperiode zijn 188 werksessies gelogd in deze vault, waarbij na elke sessie de voortgang werd vastgelegd om bij de volgende sessie direct verder te werken. De vault is tevens het Git-repository: alle wijzigingen aan documentatie, TMDL-bestanden en dashboarddefinities (PBIR-JSON) zijn versiebeheerd.

Claude Code is een AI-ondersteunde ontwikkeltool die werd ingezet als productiviteitstool gedurende alle 188 werksessies. Concreet is Claude Code gebruikt voor het schrijven en debuggen van PySpark-notebooks, het opstellen en testen van DAX-measures, het genereren van dashboardconfiguraties in JSON-formaat, en het bouwen van notebooks voor het verkennen van de API-endpoints. De regie lag bij de student: de requirements werden geformuleerd, de output beoordeeld en gecorrigeerd, en het resultaat gevalideerd met stakeholders. Een concreet voorbeeld: de dashboards zijn opgeslagen in het PBIR-formaat, waarbij elke visual een apart JSON-bestand is. De paginalayout werd ontworpen en per visual werden de benodigde measures, kleuren en interacties gespecificeerd. Claude Code genereerde de JSON-bestanden, waarna het resultaat in Power BI Desktop werd geopend, visueel gecontroleerd en waar nodig gecorrigeerd. Dit iteratieve proces maakte het mogelijk om in enkele sessies verschillende visuals met consistente styling te produceren, wat handmatig aanzienlijk meer tijd had gekost. De ontwikkelomgeving werd uitgebreid met MCP-connectoren (Model Context Protocol) die toegang gaven tot het Power BI semantic model voor het live bewerken van measures en het draaien van DAX-queries, en tot een browser voor geautomatiseerde validatie van gepubliceerde dashboards. Daarnaast werden custom skills (herbruikbare instructiesets voor terugkerende taken zoals sessie-workflow en dashboardgeneratie) en een gespecialiseerde review-agent voor dashboardfeedback geconfigureerd.

2.4. Voorbereidende trainingen

Voorafgaand aan de stage zijn drie Microsoft-certificeringscursussen gevolgd: AZ-900 (Azure Fundamentals), PL-300 (Power BI Data Analyst) en DP-600 (Fabric Analytics Engineer). AZ-900 biedt basiskennis van cloudconcepten en Azure-diensten. PL-300 behandelt datamodellering, DAX en rapportontwerp in Power BI. DP-600 focust specifiek op Fabric: lakehouse-architectuur, Spark-notebooks, pipelines en semantic models. Bij aanvang van de stage werd daarnaast een interne Algorhythm-bootcamp gevolgd over data warehousing, met nadruk op de medallion-architectuur, de Kimball-methodologie voor dimensioneel modelleren en Slowly Changing Dimensions.

3. Data-architectuur

Dit hoofdstuk beschrijft de architectuur van het dataplatform: de opslagstructuur in het lakehouse, het dimensioneel datamodel en het semantic model dat de dashboards van data voorziet.

3.1. Medallion-architectuur


Het Hawkeye-platform volgt de medallion-architectuur, een veelgebruikt patroon in moderne data-engineering waarbij data in drie opeenvolgende lagen wordt verwerkt. Elke laag heeft een duidelijke verantwoordelijkheid en bouwt voort op de vorige.

De **Bronze-laag** bevat de ruwe data zoals die uit de API's binnenkomt, opgeslagen als Delta-tabellen met toegevoegde metadata kolommen (`_source_system`, `_ingest_timestamp`, `_source_file`). Er worden in deze laag geen inhoudelijke transformaties toegepast; de data blijft een getrouwe kopie van de bron. Dit maakt het mogelijk om bij problemen altijd terug te keren naar de oorspronkelijke data. De Bronze-laag bevat 19 tabellen: 6 uit CronosCentral (employees, freelancers, former_employees, persons, companies, cars), 7 uit TIA (users, timesheet_codes, timesheets, actuals, employment_details, completion_status, landscape) en 6 uit Salesforce (account, opportunity, order__c, order_resource__c, resource__c, purchase_order__c). De timesheet-data wordt via een dubbele explode-transformatie afgevlakt van een geneste hiërarchie (gebruiker, maand, dag) naar platte rijen.

De **Silver-laag** schoont de data op: datatypes worden gestandaardiseerd, null-waarden behandeld, duplicaten verwijderd en kolommen hernoemd naar de togaether-naamconventies (snake_case, business-terminologie). Login- en gebruikersnamen worden genormaliseerd voor koppeling tussen CronosCentral en TIA. In deze laag worden ook de SCD Type II-kolommen voorbereid (`_valid_from`, `_valid_to`, `_is_current`) die het mogelijk maken om de historie van contractwisselingen bij te houden.

De **Gold-laag** bevat het business-ready sterschema: dimensie- en feitentabellen die rechtstreeks door Power BI worden geconsumeerd. Hier worden de joins gelegd tussen CronosCentral- en TIA-data, de business-logica toegepast (classificaties, drempelwaarden, afgeleide kolommen) en de data gefilterd op relevantie. Het Gold-schema bevat 23 tabellen: 9 dimensietabellen, 5 feitentabellen, een bridge-tabel, een configuratietabel, een entiteitsdimensie, 4 referentietabellen voor het semantic model en 2 mapping-tabellen.

De drie lagen zijn ondergebracht in vier Fabric-workspaces, volgens de togaether-richtlijnen: 00StorageHawkeyeDEV (het lakehouse met alle Delta-tabellen), 10IngestionHawkeyeDEV (ingestie-notebooks), 20EngineeringHawkeyeDEV (transformatie-notebooks) en 30OrchestrationHawkeyeDEV (de master-pipeline).



Architectuuroverzicht: datastroom van bronnen via medallion-lagen naar rapportage

3.2. Dimensioneel datamodel

Het Gold-sterschema volgt de Kimball-methodologie: een centraal cluster van feitentabellen omringd door gedeelde dimensietabellen met surrogate keys. Hieronder worden de belangrijkste tabellen beschreven.

`dim_employee` is de kerndimensie van het platform. De tabel bevat 221 rijen: 50 actieve medewerkers en 171 historische records. De samenstelling gebeurt via een meervoudige UNION van vijf bronnen: actieve CronosCentral-werknemers, freelancers, voormalige medewerkers, freelance partners en historische TIA-

gebruikers die niet meer in CronosCentral staan. De tabel bevat persoonlijke gegevens (naam, geboortedatum, e-mail), contractinformatie (startdatum, einddatum, contracttype, entiteit) en afgeleide kolommen zoals leeftijd, dienstjaren, leeftijdscategorie en een `is_core_workforce`-vlag die stagiairs en aannemers uitsluit. De koppeling met TIA en de entiteitstoewijzing verlopen via een meerstapsproces (zie hoofdstuk 4, T6).

`dim_date` is de kalendertabel, lopend van 2015 tot en met het huidige jaar. Het eindjaar wordt automatisch bepaald bij elke pipeline-run. Naast standaard datumattributen (jaar, kwartaal, maand, weeknummer, dagnaam) bevat de tabel Belgische feestdagen, berekend met het algoritme van Butcher voor de variabele Paasdatum, en een `is_workday`-vlag die weekends en feestdagen uitsluit.


`dim_client` bevat de genormaliseerde klantnamen. In de ruwe TIA-data komen klanten voor onder tientallen spellingsvarianten: "Janssen Pharmaceutica", "janssen-msa", "JnJ", "Janssen". Een normalisatieprocedure met regex-patronen, prefix-mapping en een handmatig beheerde vertaaltabel (36 override-regels) reduceert dit tot unieke klanten. Sinds iteratie 2 wordt deze mapping aangevuld met Salesforce-data (zie 6.3).

`dim_timesheet_code` beschrijft de circa 1.400 projectcodes uit TIA, geclassificeerd in categorieën: billable, intern, ziekte, opleiding, vakantie en overig. Deze classificatie is de basis voor de berekening van billability en utilization.

`fact_timesheet` is de centrale feitentabel met circa 133.000 rijen, met één rij per medewerker per dag per activiteitstype. De tabel bevat zes foreign keys (naar employee, date, timesheet_code, activity_type, client en entity) en de meetwaarden `normal_hours` en `extra_hours`. Een boolean `is_billable` markeert of de uren factureerbaar zijn.

`fact_headcount_monthly` bevat maandelijks headcount-snapshots: per medewerker per maand één rij met het actieve contracttype en de entiteit. Deze tabel maakt het mogelijk om headcount-trends te analyseren zonder dubbeltellingen bij contractwisselingen: per persoon per maand telt enkel het meest recente contract.

`dim_config` is een configuratietabel met 20 rijen die KPI-drempelwaarden bevatten: het billability-doel (65%), de bench-detectiegrens, de dagvullingsdrempel en andere business rules. Door deze waarden in een tabel te plaatsen in plaats van hard-coded in DAX-formules, kunnen ze worden aangepast zonder de measures te wijzigen.



Dimensioneel datamodel: sterschema met dimensie- en feitentabellen

3.3. Semantic model

Bovenop het Gold-sterschema ligt het Power BI semantic model, gedefinieerd in TMDL-formaat (Tabular Model Definition Language). TMDL is een tekstgebaseerd formaat dat versiebeheer in Git mogelijk maakt, zodat elke wijziging aan een measure of relatie is traceerbaar als een diff.

Het model bevat DAX-measures georganiseerd in displayfolders per domein (Basis, Headcount, Operations, HR Analytics, Fleet, Klanten, Registratie). Naast reguliere measures bevat het model ook talrijke formatting-measures die bijvoorbeeld entiteitsspecifieke kleuren retourneren voor conditionele

opmaak, en subtitle-measures die dynamische context tonen onder KPI-kaarten (bijvoorbeeld "31 werknemers + 19 freelancers" of "rolling 12 maanden").

Een voorbeeld van een complexere measure is `Headcount`, die contextgevoelig reageert op filters:

```
VAR _hasPeriod = ISFILTERED(dim_date[year])
VAR _maxDate = CALCULATE(
    MAX(fct_headcount_monthly[date_key]),
    fct_headcount_monthly[date_key] <= _currentMonthKey,
    ALL(fct_headcount_monthly))
VAR _snapshot = CALCULATE(
    COUNTROWS(fct_headcount_monthly),
    fct_headcount_monthly[date_key] = _maxDate,
    fct_headcount_monthly[is_core_workforce] = TRUE)
VAR _yearly = CALCULATE(
    DISTINCTCOUNT(fct_headcount_monthly[employee_key]),
    fct_headcount_monthly[is_core_workforce] = TRUE)
RETURN IF(_hasPeriod, _yearly, _snapshot)
```

Zonder jaarfilter toont deze measure de snapshot van de meest recente maand (hoeveel mensen er op dat moment actief zijn). Met een jaarfilter schakelt de measure over naar een `DISTINCTCOUNT`: hoeveel unieke personen waren minstens een maand actief in dat jaar. Dit onderscheid is cruciaal omdat de snapshot-waarde misleidend zou zijn bij een gefilterd jaar: vertrokken medewerkers die in eerdere maanden van dat jaar wel actief waren, zouden dan ontbreken in het totaal.

4. Data engineering

Dit hoofdstuk beschrijft hoe de data van bron naar dashboard stroomt: de ingestie uit API's, de transformaties in het lakehouse en de kwaliteitsbewaking.

4.1. Ingestie

De ingestie-notebooks halen data op uit de bronsystemen en slaan deze op als Delta-tabellen in de Bronze-laag. Elke notebook volgt hetzelfde patroon: authenticeren, data ophalen, metadatakolommen toevoegen en wegschrijven.

Voor CronosCentral verloopt de authenticatie in drie stappen. Eerst wordt een Azure AD-token aangevraagd via client credentials (client ID + secret). Vervolgens wordt dit token uitgewisseld bij de CronosCentral API voor een applicatiespecifiek bearer-token. Met dit token worden GraphQL-queries uitgevoerd. Een typische query haalt alle velden van een entiteit op in één aanroep:

```
{
  employees {
    id person login firstName lastName displayName
    dateOfBirth startDate endDate dateEmployed
    isActive activeContractCompanyFullName
    contractTypeName
  }
}
```

Voor TIA verloopt de authenticatie eenvoudiger via standaard OAuth2 met client credentials. De REST-endpoints worden gepagineerd opgehaald met rate-limiting (1,5 seconde pauze tussen requests) en exponentieel terugvallen bij 429- of 5xx-fouten.

De timesheet-data uit TIA heeft een bijzondere structuur: de API retourneert een geneste hiërarchie van gebruiker → maand → dag → activiteit. In de Bronze-laag wordt deze hiërarchie "geëxplodeerd" naar platte tabellen via twee stappen, zodat elke dagrij een apart record wordt.

Alle notebooks loggen hun uitvoering naar twee Delta-tabellen: `job_runs` (per notebook-uitvoering: start, einde, status, aantal rijen) en `task_runs` (per deeltaak). Dit maakt het mogelijk om in de pipeline te zien wanneer data voor het laatst succesvol is bijgewerkt en hoeveel records zijn verwerkt.

	ABC task_run_id	ABC job_run_id	ABC task_name	task_start_ts	task_end_ts	ABC status	ABC input_param...	ABC output_details	ABC task...
1	62ab63a2-0299-4...	3ea1e98b-5699-4...	gold_dim_employ...	2026-04-11T08:3...	2026-04-11T08:3...	success	("phase": 3)	("signal_c": 5, "tot...	Signaal C
2	a667d71a-cada-4...	3ea1e98b-5699-4...	gold_fct_completi...	2026-04-11T08:3...	2026-04-11T08:3...	success	("phase": 3)	("rows": 22391)	22391 rijen
3	01779eb4-9257-4...	3ea1e98b-5699-4...	gold_dim_employ...	2026-04-11T08:3...	2026-04-11T08:3...	success	("phase": 2)	("matched": 50, "t...	50/221 g
4	8ae9b9d5-5c08-4...	5d56bc28-ec91-4...	silver_tia_comple...	2026-04-11T03:0...	2026-04-11T03:0...	success	("bronze": "bronz...	("rows": 7901)	7901 rijen
5	5d114982-9dcf-4...	5d56bc28-ec91-4...	silver_tia_employ...	2026-04-11T03:0...	2026-04-11T03:0...	success	("bronze": "bronz...	("rows": 414)	414 rijen
6	6d88a29e-b6bd-4...	5d56bc28-ec91-4...	silver_cc_former_e...	2026-04-11T03:0...	2026-04-11T03:0...	success	("bronze": "bronz...	("rows": 248)	248 rijen
7	906051c1-efb9-4b...	5d56bc28-ec91-4...	silver_tia_timeshe...	2026-04-11T02:5...	2026-04-11T02:5...	success	("bronze": "bronz...	("rows": 1416)	1416 rijen
8	4a6768d8-a237-4...	5d56bc28-ec91-4...	silver_tia_timeshe...	2026-04-11T02:5...	2026-04-11T02:5...	success	("bronze": "bronz...	("rows": 145980)	145980 rijen
9	60754f38-7d34-4...	81cd176-d06f-4...	codes_rebuild	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "TIA", "...	("new": 1416, "tot...	1416 cod
10	5a642c27-acac-4...	81cd176-d06f-4...	bronze_tia_landsc...	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "TIA", "...	("new": 98, "total...	98 rijen
11	12b0eaf6-bc96-40...	81cd176-d06f-4...	bronze_tia_actua...	2026-04-11T02:4...	2026-04-11T02:4...	failed	("source": "TIA", "...		[DELTA_5]
12	79dc8001-3383-4...	81cd176-d06f-4...	bronze_tia_compl...	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "TIA", "...	("new": 134, "total...	134 rijen
13	47f3ec60-9af7-4...	81cd176-d06f-4...	bronze_tia_emplo...	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "TIA", "...	("new": 536, "total...	536 rijen
14	ce1f3534-5960-4...	81cd176-d06f-4...	bronze_cc_compa...	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "Crono...	("new": 4, "total..."	4 rijen
15	72729670-2137-4...	81cd176-d06f-4...	bronze_cc_cars	2026-04-11T02:4...	2026-04-11T02:4...	success	("source": "Crono...	("new": 34, "total..."	34 rijen

Task_runs: logging per deeltaak met status, tijdstempel en rijtellingen

4.2. Transformaties

De transformaties van Silver naar Gold omvatten 19 genummerde stappen (T1-T19) die in volgorde worden uitgevoerd door het Gold-notebook. De belangrijkste worden hieronder beschreven.

T1: Kalender met Belgische feestdagen. De `dim_date`-tabel wordt gegenereerd voor het bereik 2015-huidig jaar. Belgische feestdagen worden berekend met het algoritme van Butcher (voor Pasen en afgeleide feestdagen zoals Hemelvaart en Pinksteren) aangevuld met vaste feestdagen. Het resultaat is een `is_belgian_holiday`-vlag per datum.

T2: Klantnaam-normalisatie. De ruwe klantnamen uit TIA worden opgeschoond in drie stappen. Eerst haalt een regex de klantnaam uit de `TsCode`-string (tekst tussen haakjes, bijvoorbeeld "CC PM Senior (Indaver Tenforce)" wordt "Indaver Tenforce"). Vervolgens worden bekende varianten herleid via een vertaaltabel van handmatige overrides (bijvoorbeeld "EOC" wordt "Euroclear") en een prefix-mapping die namen met een gemeenschappelijk beginwoord samenvoegt (bijvoorbeeld "janssen-msa", "JnJ" en "Janssen Pharmaceutica" worden allemaal "J&J"). Ten slotte worden resterende duplicaten verwijderd via een genormaliseerde sleutel (hoofdletters, zonder spaties en koppelteken), waarbij de meest gebruikte variant behouden blijft.

T6: Entity resolution. Entity resolution is het proces waarbij records uit verschillende systemen worden herkend als dezelfde persoon of organisatie. Dit is de meest complexe transformatie en omvat twee deelproblemen: de persoonskoppeling tussen systemen en de entiteitstoewijzing.

Het eerste deelprobleem is de **persoonskoppeling**: CronosCentral en TIA gebruiken verschillende identifiers voor dezelfde personen (een `person-UUID` versus een `username`). De koppeling verloopt via een meervoudige UNION: eerst worden actieve CronosCentral-personen gejoined met TIA-gebruikers op login, daarna worden ongematchte TIA-gebruikers, historische timesheet-gebruikers, vertrokken medewerkers en freelance partners als fallback-lagen toegevoegd. Duplicaten worden gemerged via `display_name` matching en CC-login patroonherkenning.

Het tweede deelprobleem is de **entiteitstoewijzing**: bepalen bij welk bedrijf (Algorhythm Group, Bright Dots, togaether, etc.) een persoon hoort. Dit verloopt via een waterval van acht stappen, van meest naar minst betrouwbaar:

1. Administratieve override via CC freelancer comment (bijv. "Behoort tot @togaether.be")
2. TIA employment details (huidige dienstperiode)
3. Hardcoded override (XploData → Algorhythm Group)
4. Divisie-string in CC bedrijfsnaam (bijv. "divisie Common Sense AI")
5. CC bedrijfsnaam met rechtsvorm gestript (bijv. "Bright Dots NV" → "Bright Dots")
6. CC contractdivisie-veld
7. E-maildomein mapping (bijv. @brightdots.be → Bright Dots)
8. Fallback: Algorhythm Group

Het resultaat is een `employee_key` die in alle feitentabellen als foreign key wordt gebruikt, samen met een `entity_resolution_method` die vastlegt via welke stap de toewijzing is bepaald.

T7: Historische entiteitstoewijzing. De waterval hierboven bepaalt de huidige entiteit. Voor historische analyses, bijvoorbeeld hoeveel uren in 2022 aan togaether toebehoren, is de entiteit op dat moment nodig. De TIA employment details bevatten alle dienstperiodes per gebruiker met start- en einddatum. Deze worden omgezet naar een bridge-tabel (`gold_bridge_employee_entity`) met `valid_from` en `valid_to` per periode. De feitentabellen joinen hierop via `username + datum BETWEEN valid_from AND valid_to`, zodat uren en headcount worden toegewezen aan de entiteit die op dat moment actueel was. De bridge wordt elke run volledig herbouwd uit de brondata.

T16: Headcount-snapshots. Per maand wordt voor elke medewerker bepaald of deze actief was, op basis van `start_date` en `end_date`. Bij contractwisselingen (bijvoorbeeld van werknemer naar freelancer) wordt per persoon per maand enkel het meest recente contract behouden, wat dubbeltellingen voorkomt.


T17: Stagiairdetectie. Stagiairs worden geïdentificeerd via drie onafhankelijke signalen: (A) het contracttype in CronosCentral is "internship", (B) de persoon is vertrokken en heeft minder dan drie maanden echte uren geregistreerd, of (C) al hun niet-systeemuren staan op "Stageopdracht"-timesheetcodes. Elk signaal is op zichzelf voldoende om de vlag `is_stagiair = TRUE` te zetten. Signalen

A en B worden toegepast bij de opbouw van dim_employee, signaal C pas na fase 3 wanneer de timesheet-data beschikbaar is. Stagiairs worden uitgesloten uit het kernteam via de is_core_workforce-vlag.


4.3. Orchestratie

De notebooks worden aangestuurd door pl_master_hawkeye, een Fabric-pipeline in de 30OrchestrationHawkeyeDEV-workspace. De pipeline voert de notebooks sequentieel uit: eerst de ingestie (CronosCentral, dan TIA en Salesforce), dan de Bronze-transformatie, dan Silver, en ten slotte Gold. De sequentiële uitvoering is noodzakelijk omdat parallele schrijfoperaties naar dezelfde Delta-tabel fouten veroorzaken (ConcurrentAppendException, een fouttype dat optreedt wanneer meerdere processen tegelijk naar dezelfde tabel schrijven).

De pipeline draait dagelijks via een Fabric-schedule. Bij een fout in een notebook stopt de pipeline en worden de foutreden gelogd in de job_runs-tabel, zodat het probleem kan worden gediagnosticeerd zonder de volledige pipeline opnieuw te draaien.



Fabric workspaces met de vier Hawkeye-omgevingen en een ingestie-notebook



Succesvolle runs van pl_master_hawkeye met de pipelinestructuur

4.4. Datakwaliteit

Datakwaliteit wordt op drie niveaus bewaakt, conform de togaether Data Quality Checklist die zes dimensies definieert: nauwkeurigheid, volledigheid, consistentie, actualiteit, validiteit en uniekheid.

In de **Bronze-laag** worden geen inhoudelijke checks uitgevoerd: de data wordt opgeslagen zoals ontvangen. Dit is bewust: als de brondata fouten bevat, moeten die traceerbaar blijven.

In de **Silver-laag** worden datatypes afgedwongen (datums als Date, getallen als Decimal), null-waarden geïnterpreteerd en duplicaten verwijderd. Een concreet voorbeeld: het veld `VEmployee.DateEmployed` was aanvankelijk leeg voor alle 161 records. Na melding aan de leverancier (2sky) is dit opgelost: 135 records zijn nu gevuld, de resterende 26 zijn historische inactieve records zonder enige datum-informatie.

In de **Gold-laag** gelden business rules: de headcount-deduplicatie voorkomt dubbeltellingen bij contractwisselingen, de entity resolution koppelt records met een minimale foutmarge, en de `dim_config`-tabel bevat valideerbare drempelwaarden voor KPI-berekeningen.

5. Dashboards

Dit hoofdstuk beschrijft de Power BI dashboards: het visuele ontwerp, de vier rapporten en hun belangrijkste functionaliteiten.

5.1. Ontwerp


Het visuele ontwerp is vastgelegd in een stylegids die is ontwikkeld aan de hand van Hawkeye 5.0 (een voorgaand prototype), de websites van de vier Algorhythm-entiteiten en algemene dashboard-designprincipes.

De kern van het ontwerp is een onderscheid tussen structuurkleuren en datakleuren. Navy (#020032) wordt gebruikt voor structurele elementen: de header, paginatitels en navigatie. De vijf entiteitskleuren (oranje voor Algorhythm Group, blauw voor Bright Dots, lichtblauw voor Common Sense AI, paars voor Georhythm en groen voor togaether) worden uitsluitend gebruikt voor data: staafdiagrammen, lijngrafieken en legenda's. Dit onderscheid voorkomt dat structurele en data-elementen visueel door elkaar lopen.

De pagina-indeling is gestandaardiseerd over alle rapporten: een navy header met navigatie bovenaan, daaronder een filterzone en een contentzone. Overzichtspagina's gebruiken horizontale tile slicers in de filterzone; detailpagina's hebben een linkersidebar met slicers voor filtering op entiteit, contracttype en andere dimensies.

Het thema is vastgelegd in een `hawkeye-theme.json`-bestand dat door alle drie de rapporten wordt gedeeld. Het bevat 41 datakleuren (in volgorde van de vijf entiteitskleuren, gevolgd door accenten en semantische kleuren), typografie-instellingen (DIN 28pt voor KPI-waarden, Segoe UI voor labels) en standaardopmaak voor randen, schaduwen en achtergrondkleuren.

5.2. Home dashboard




Het Home dashboard is de centrale landingspagina van het Hawkeye-platform. De pagina toont de Hawkeye-windroos op een navy achtergrond en biedt drie navigatieknoppen waarmee de gebruiker direct naar het HR-, Operations- of Fleet-rapport navigeert. De windroos met "Hawkeye 360°" in het centrum fungeert als visueel herkenningspunt en versterkt de projectidentiteit. Het ontwerp is bewust minimalistisch gehouden: geen data, geen filters, alleen een duidelijk startpunt.

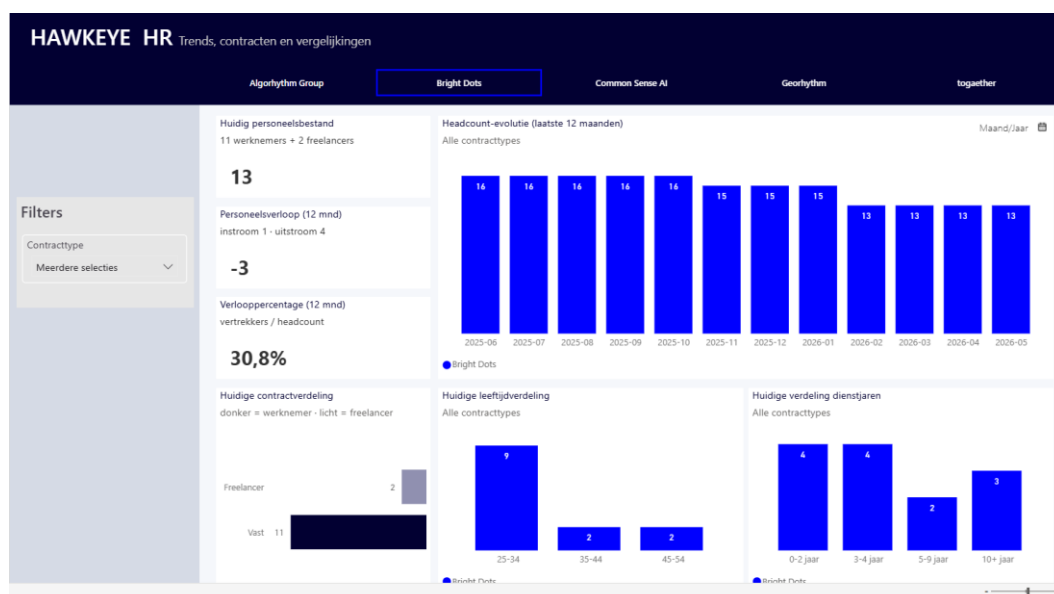
5.3. HR-rapport

Het HR-rapport bevat negen pagina's, waarvan drie verborgen tooltip-pagina's, en richt zich op personeelsinformatie, demografische analyse en individuele medewerkersdetails.

Overzicht toont de vier primaire KPI's als kaartvisualisaties: headcount, freelancerratio, gemiddelde diensttijd en gemiddelde leeftijd. Elke kaart heeft een dynamische subtitel die context biedt; de headcount-kaart toont bijvoorbeeld "30 werknemers + 16 freelancers". Daaronder staan een gestapeld staafdiagram met medewerkers per entiteit (donker voor werknemers, licht voor freelancers) en een kaart met de woonlocaties van medewerkers en de drie kantoorlocaties.



HR Overzicht: KPI-kaarten, headcount per entiteit en locatiekaart



HR Analyse: headcount-evolutie, turnover KPI's en verdelingen gefilterd op Bright Dots

Analyse biedt trendanalyse via drie KPI-kaarten: huidig personeelsbestand, personeelsverloop (instroom en uitstroom) en verlooperpercentage. De turnover-measures werken met een rolling 12-maandenlogica. Een kolomdiagram toont de headcount-evolutie, met een toggle om te schakelen tussen jaar- en

maandweergave. Bij hover over een kolom toont een tooltip-pagina de namen van blijvers, nieuwkomers en vertrekkers voor die periode. Daaronder staan drie verdelingen: contracttype (vast versus freelancer), leeftijdscategorie en dienstjaren. Een sidebar met een contracttype-slicer filtert alle visuals op de pagina.

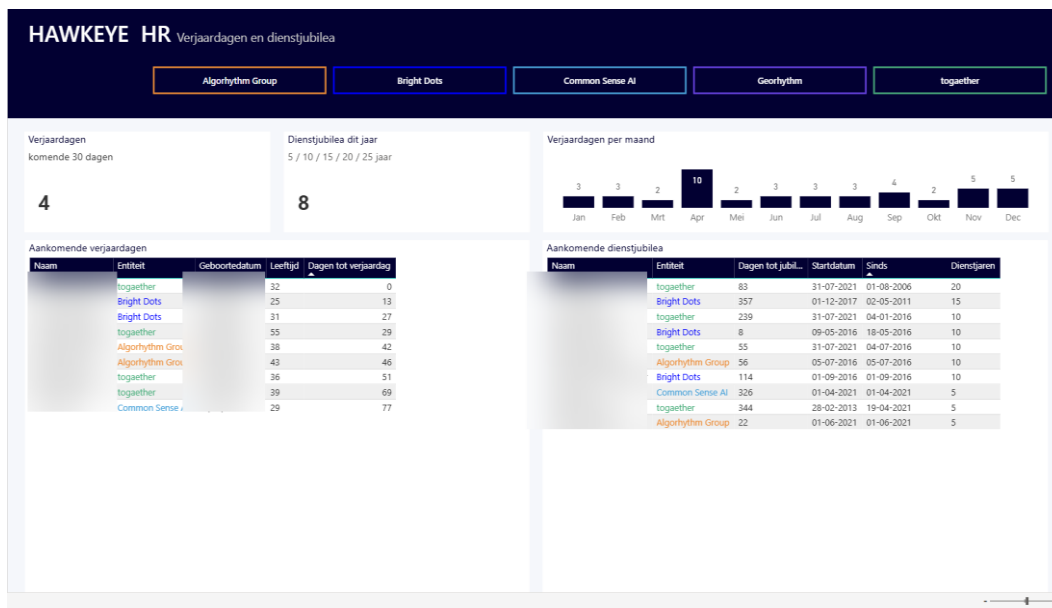
Medewerkers is een tabeloverzicht van alle actieve personeelsleden, zodat managers snel kunnen filteren op entiteit, contracttype of dienstverband. De tabel toont per medewerker de entiteit, woonplaats, leeftijd, type (werknemer of freelancer), startdatum, contractvorm, dienstjaren en anciënniteitsdatum. Een sidebar met type- en contractslicers filtert de tabel, en de entiteitslicer bovenaan laat toe om per entiteit te filteren.

<

HR Medewerkers: tabeloverzicht per entiteit met type- en contractslicers

Detail is een drillthrough-pagina die toelaat om vanuit een KPI of grafiek direct door te klikken naar de onderliggende medewerkers, bijvoorbeeld alle freelancers of alle werknemers met minder dan twee dienstjaren. De header toont dynamisch de geselecteerde entiteit en het aantal medewerkers. De tabel bevat dezelfde kolommen als de medewerkerspagina, aangevuld met een actief-kolom. Een sidebar met vier slicers (type, contract, status en team) verfijnt de selectie verder.


Verjaardagen combineert twee perspectieven, zodat managers proactief verjaardagen en jubilea kunnen opvolgen: aankomende verjaardagen en dienstjubilea. Twee KPI-kaarten tonen het aantal verjaardagen in de komende 30 dagen en het aantal dienstjubilea (5, 10, 15, 20 of 25 jaar) dit jaar. Een staafdiagram geeft de verdeling van verjaardagen per maand weer, met de huidige maand gehighlight. Daaronder staan twee tabellen: links de aankomende verjaardagen met geboortedatum, leeftijd en dagen tot de verjaardag, rechts de aankomende dienstjubilea met startdatum en dienstjaren.



HR Verjaardagen: KPI's, maandverdeling en aankomende jubilea

5.4. Operations-rapport

Het Operations-rapport richt zich op urenregistratie, consultantprestaties en klantconcentratie. Het bevat zes hoofdpagina's.



Operations Overzicht: butterfly chart, KPI-kaarten en YoY-trendlijn

Overzicht toont vijf operationele KPI-kaarten: billability-percentages, totaal gewerkte uren, ziekteverzuim, opleidingspercentage en registratiegraad, elk met een delta-indicator ten opzichte van de vorige periode. Het centrale visuele element is een butterfly chart: een gestapeld staafdiagram waarbij niet-factureerbare uren als negatieve waarden links worden getoond en factureerbare uren rechts. Kleurbanden geven het billability-percentages aan: groen bij 65% of meer, oranje tussen 50% en 65%, en rood onder 50%. Dit patroon maakt het in één blik duidelijk hoeveel capaciteit wordt benut en waar ruimte is voor verbetering. Rechts toont een gestapelde balk de verdeling van non-billable uren (intern, ziekte, opleiding, vakantie) voor de geselecteerde maand, en daaronder een YoY-lijndiagram dat het billability-percentages per maand vergelijkt met het voorgaande jaar. Een sidebar met jaar-, maand-, modus- en werknemerslicers filtert alle visuals op de pagina.

De implementatie van de butterfly chart vereiste een specifiek DAX-patroon: aparte measures per kleurband (BF Green, BF Orange, BF Red) met statische kleurkoppelingen per measure-metadata, omdat Power BI geen conditionele kleuring ondersteunt op individuele segmenten van een gestapeld staafdiagram.

Een billability/utilization-toggle laat de gebruiker schakelen tussen twee modi. De toggle is geïmplementeerd als een disconnected slicer (`_RateSwitch`) met 25 wrapper-measures die afhankelijk van de geselecteerde modus de juiste KPI tonen. Het verschil: billability meet het aandeel factureerbare uren ten opzichte van het totaal, terwijl utilization de factureerbare uren deelt door het totaal exclusief verlof en feestdagen.

Consultants biedt een ranking waarmee onderbezette consultants en topperformers snel zichtbaar worden. De tabel is gesorteerd op billability- of utilization-percentages afhankelijk van de geselecteerde modus, en bevat per consultant het aantal werkdagen, billable en utilization percentage met conditionele kleuring (groen, oranje, rood), ziekte-, opleidings-, verlof- en overuren, het aantal klanten, de topklant, en de vullings- en afrondingsgraad. Een sidebar met jaar- en maandslicers filtert de weergave.

HAWKEYE Operations

Ranking, uren en klanten per consultant

Algorithmen Group

Bright Dots

Common Sense AI

Georhythm

together

Consultant ranking op utilization % sep 2025

#	Naam	Huidige Entiteit	# Dagen	Billable %	Utilization %	Ziekte (u)	Opleiding (u)	Verlof (u)	Overuren (u)	# Klanten	Top klant	Vulling	Afgerond
1	Bright Dots	22,0	100,0%	100,0%	0,0	0,0	0,0	0,0	0,0	1		100%	100%
1	Bright Dots	22,0	54,5%	100,0%	0,0	0,0	80,0	0,0	1			100%	100%
1	Bright Dots	22,0	100,0%	100,0%	0,0	0,0	0,0	0,0	2			100%	100%
1	Bright Dots	22,0	77,3%	100,0%	0,0	0,0	40,0	0,0	1			100%	100%
2	Bright Dots	22,0	99,4%	99,4%	0,0	0,0	0,0	0,0	1			100%	100%
3	Bright Dots	22,0	95,5%	95,5%	8,0	0,0	0,0	0,0	1			100%	100%
4	Bright Dots	22,0	77,3%	94,4%	0,0	0,0	32,0	0,0	4			100%	100%
4	Bright Dots	22,0	77,3%	94,4%	0,0	8,0	32,0	0,0	1			100%	100%
5	Bright Dots	22,0	50,0%	91,7%	0,0	0,0	80,0	0,0	1			100%	100%
6	Bright Dots	22,0	86,4%	86,4%	16,0	8,0	0,0	0,0	2			100%	100%
7	Bright Dots	22,0	81,8%	83,7%	20,0	8,0	4,0	0,0	1			100%	100%
8	Bright Dots	22,0	50,0%	68,8%	0,0	4,0	48,0	0,0	2			100%	100%
9	Bright Dots	22,0	63,6%	68,3%	0,0	0,0	12,0	0,0	1			100%	100%
10	Bright Dots	22,0	54,5%	60,0%	0,0	0,0	16,0	0,0	1			100%	100%
11	Bright Dots	22,0	11,9%	13,8%	0,0	0,0	24,0	0,0	1			100%	100%
		330,0			44,0	28,0	368,0	0,0	15			100%	100%

Filters

Jaar

2025

Maand

september


Operations Consultants: ranking met conditionele kleuring op billability

Consultant Detail toont het profiel van een individuele consultant. Vier KPI-kaarten geven werkdagen, billability en utilization (met delta ten opzichte van het teamgemiddelde), en het aantal klanten met de topklant voor de geselecteerde maand. Een gestapeld kolomdiagram toont de urenverdeling per maand met vaste kleuren per uren type: navy voor factureerbare uren en gedempte, herkenbare tinten voor intern werk, ziekte, opleiding, vakantie en overig. Een tweede kolomdiagram splitst de billable dagen uit per klant. Een YoY-lijndiagram vergelijkt het billability-percentages met het voorgaande jaar.




Operations Consultant detail: KPI's, urenverdeling en klantportfolio per maand

Registratie Detail toont per consultant de status van de urenregistratie, zodat snel duidelijk is of alle uren correct en volledig zijn geregistreerd. Drie KPI-kaarten geven de afrondingsgraad, het aantal timesheetcodes en het totaal geregistreerde uren voor de geselecteerde maand. Een tabel toont per timesheetcode de activiteit, eigenaar, of de code factureerbaar is, de afrondingsstatus en het aantal uren. Niet-factureerbare codes worden grijs weergegeven. Een maandslicer bovenaan laat toe om per maand te navigeren.




Operations Registratie detail: timesheetcodes per consultant per maand

Klanten biedt inzicht in het klantportfolio en de klantconcentratie: welk percentage van de uren gaat naar welke klant, en hoe evolueert het klantenbestand over tijd. Vier KPI-kaarten tonen het aantal actieve klanten, de concentratie van de topklant als percentage van de totale uren, het aantal nieuwe klanten en het aantal inactieve klanten (rood gemarkeerd). Een horizontaal staafdiagram rangschikt de klanten op uren met kleurcodering voor bestaande, nieuwe en terugkerende klanten. Een toggle schakelt tussen ranking- en tijdlijnweergave. Een kolomdiagram toont het klantenverloop per maand, zodat patronen in klantacquisitie en -verlies snel zichtbaar worden. Een drillthrough naar de klantdetailpagina toont het volledige profiel van een klant met consultants, uren en trendlijn.



Operations Klanten: klantportfolio, concentratie en klantenverloop

Klant Detail toont het volledige profiel van een individuele klant, met focus op de vraag: hoeveel capaciteit gaat naar deze klant, wie werkt er en hoe evolueert het volume? Vier KPI-kaarten geven de billable uren, het aantal ingezette consultants, het aandeel van de klant in de totale uren en het gemiddeld aantal uren per consultant. Een tabel toont de ingezette consultants met hun uren en aandeel. Het kolomdiagram splitst de uren per maand uit naar entiteit, zodat verschuivingen in de inzet zichtbaar worden, en een YoY-lijdendiagram toont of het volume bij deze klant groeit of krimpt ten opzichte van vorig jaar.



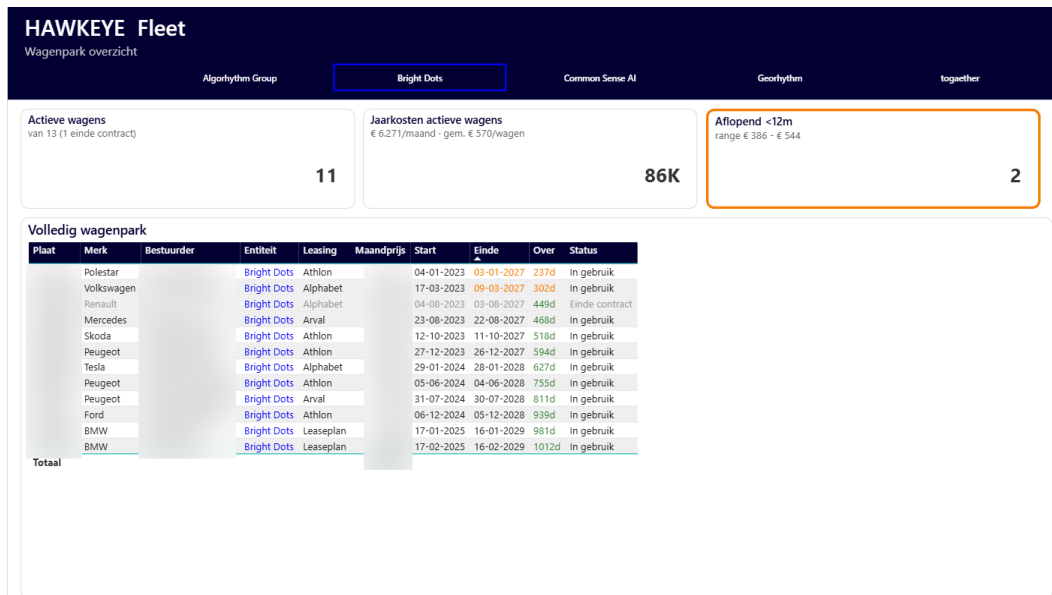
Operations Klant detail: consultants, urenverdeling per entiteit en YoY-trend

Detailpagina's voor consultants en klanten bestaan in twee varianten. De eerste variant is de drillthrough-pagina, die opent vanuit een andere pagina met de geselecteerde consultant of klant als filter. Deze variant biedt snelle toegang vanuit een grafiek of tabel, maar laat niet toe om ter plekke te wisselen naar een andere selectie. Daarom is er een tweede variant met handmatige slicers, zodat de gebruiker vrij kan navigeren tussen consultants of klanten zonder terug te keren naar de overzichtspagina. Een knop op de drillthrough-pagina navigeert naar deze vrije variant.

5.5. Fleet-rapport


Het Fleet-rapport is het kleinste van de drie, met twee inhoudelijke pagina's.

Overzicht geeft een volledig beeld van het wagenpark. Drie KPI-kaarten tonen het aantal actieve wagens, de totale jaarkosten (met gemiddelde per wagen) en het aantal contracten dat binnen 12 maanden afloopt (oranje gemarkeerd). Een tabel toont het volledige wagenpark met nummerplaat, merk, bestuurder, entiteit, leasemaatschappij, maandprijs, start- en einddatum, resterende dagen en status. Contracten die bijna aflopen worden visueel gemarkeerd, zodat tijdige verlenging of vervanging mogelijk is.



Fleet Overzicht: wagenpark, jaarkosten en aflopende contracten

Detail analyseert de leasekosten vanuit drie invalshoeken: per leasemaatschappij, per merk en per entiteit. Een dynamische insight-kaart signaleert opvallende kostenverschillen, zoals welke maatschappij duurder is en hoeveel besparing mogelijk is. Drie staafdiagrammen vergelijken de gemiddelde maandprijs per leasemaatschappij, tonen de merkverdeling met unieke merkkleuren, en splitsen de kosten uit per entiteit. Slicers voor leasemaatschappij en merk laten toe om de analyse te verfijnen.



Fleet Detail: leasekosten per maatschappij, merkverdeling en kosten per entiteit

6. Iteratie 2: Salesforce

De eerste vijf hoofdstukken beschrijven iteratie 1: de integratie van CronosCentral en TIA tot een werkend platform met dashboards. In de laatste weken van de stage is iteratie 2 opgestart: de integratie van Salesforce als derde bronsysteem. Het doel was niet om een volledig Sales-dashboard te bouwen, maar om het fundament te leggen zodat een opvolger hierop kan voortbouwen: de data ophalen, opschonen en koppelen aan het bestaande datamodel.

6.1. Verkenning

Salesforce is het CRM-systeem (Customer Relationship Management) van Algorhythm, waarin klantrelaties, sales-opportunities en projectorders worden beheerd. De toegang verliep via de Salesforce REST API met OAuth2-authenticatie, waarbij de credentials werden opgeslagen in Azure Key Vault.

De verkenning omvatte 19 Salesforce-objecten. Daarvan bleken er 6 relevant voor Hawkeye. De standaard Order- en Contract-objecten waren leeg: Algorhythm gebruikt custom objecten (Order__c en Order_Resource__c) voor projectorders. De overige lege of dubbele objecten werden uitgesloten.

De zes geselecteerde objecten zijn: Account (458 klanten met sector, entiteit en status), Opportunity (1.088 deals in de sales pipeline), Order__c (659 projectorders met businessmodel en tarieven), Order_Resource__c (1.025 consultant-toewijzingen met kostprijs en verkooptarief), Resource__c (183 medewerkers intern en extern) en Purchase_Order__c (340 PO-budgetten per project).

Per veld werd een governance-classificatie toegepast in overleg met de stagementor: niet-gevoelige velden (klantnaam, sector, status) werden direct opgehaald, privacygevoelige velden (BTW-nummer, e-mailadres, telefoonnummer) werden niet opgehaald uit de API, en financieel gevoelige velden (tarieven, dealwaarden, PO-bedragen) werden opgehaald maar geanonimiseerd.

6.2. Pipeline

De Salesforce-pipeline volgt hetzelfde medallion-patroon als de bestaande CronosCentral/TIA-pipeline en bestaat uit vier notebooks.

Ingestie (nb_ingest_sf) haalt de zes objecten op via SOQL-queries (Salesforce Object Query Language) met automatische paginering en slaat ze op als JSON in de landing zone. De authenticatie verloopt via OAuth2 password flow met credentials uit Azure Key Vault.

Bronze (nb_bronze_metadriven) werd uitgebreid met zes configuratie-entries voor de Salesforce-tabellen. Een extra transformatie stript HTML-tags uit rich text-velden die Salesforce retourneert (bijvoorbeeld klantnamen in Order_Resource__c bevatten <p>-tags).

Silver (nb_silver_sf) schoont de zes tabellen op: kolomnamen worden hernoemd naar snake_case, datatypes gestandaardiseerd en financieel gevoelige bedragen geanonimiseerd. De anonimisering gebruikt een reproduceerbare factor van +/-15% per record, zodat verhoudingen zoals marge-percentages correct blijven maar exacte bedragen niet herleidbaar zijn.

Gold (nb_gold_sf) integreert de Salesforce-data met het bestaande datamodel. De belangrijkste output is de automatische klantenmapping (zie 6.3) en een verrijkte klanttabel (gold_sf_account_enriched) met sector, entiteitstoewijzing en bedrijfsgrootte uit Salesforce.

6.3. Klantenmapping

Tot aan iteratie 2 werd de klantenmapping volledig beheerd via een handmatige dictionary van 36 override-regels in het Gold-notebook. Elke nieuwe klant die in TIA verscheen onder een onbekende naam moest handmatig worden toegevoegd. Salesforce biedt een structurele oplossing: het systeem bevat gestandaardiseerde klantnamen die als referentie kunnen dienen.

De automatische mapping werkt in vier stappen, van meest naar minst betrouwbaar. Ten eerste de TIA_Code bridge, de meest betrouwbare methode: als een consultant-toewijzing in Salesforce (Order_Resource__c) een ingevulde TIA_Code__c heeft, wordt die gejoint op de bestaande dim_timesheet_code. Via de client_key op die timesheet-code is de koppeling met dim_client exact, zonder naamvergelijking. Deze bridge matcht 42 van de 103 Salesforce-accounts. Ten tweede een handmatige vertaaltabel voor namen die te veel afwijken (zoals "JNJ - R&D BT" versus "J&J"). Ten derde exacte naamovereenkomst. Ten vierde genormaliseerde match waarbij bedrijfssuffixen (BV, SA, NV) worden gestript en spaties en hoofdletters genormaliseerd.

Van de 103 unieke Salesforce-klantnamen worden er 80 automatisch gekoppeld. De resterende 23 vereisen een handmatige vertaling, wat normaal is bij master data management: geen enkel systeem lost 100% naamvariaties automatisch op.

De klantenmapping is hiermee futureproof geworden: nieuwe klanten die in Salesforce verschijnen, worden bij de volgende pipeline-run automatisch opgepikt. De TIA_Code bridge wordt betrouwbaarder naarmate het veld TIA_Code__c vaker wordt ingevuld bij nieuwe toewijzingen. De vulgraad is gestegen van 1% in 2020 naar 67% in 2026.

6.4. Resultaat en overdracht

De Salesforce-integratie levert drie concrete resultaten op. Ten eerste is de klantenmapping geautomatiseerd: 80 van de 103 Salesforce-klantnamen worden zonder menselijke tussenkomst gekoppeld aan het bestaande datamodel. Ten tweede is klantverrijking beschikbaar: sector, bedrijfsgrootte en entiteitstoewijzing uit Salesforce staan klaar om aan de dashboards te koppelen. Ten derde is de data voor marge- en sales-analyses aanwezig in het lakehouse: consultant-toewijzingen met (geanonimiseerde) tarieven, projectorders met businessmodel, en PO-budgetten.

De Salesforce-data is nog niet verwerkt in de Power BI dashboards. De pipeline, de opgeschoonde tabellen en de klantenmapping vormen het fundament waarop een opvolger kan voortbouwen om een Sales-dashboard of marge-KPI's te realiseren.

7. Besluit

7.1. Terugblik

Er werd een werkend dataplatform gebouwd dat drie bronsystemen integreert via geautomatiseerde pipelines en drie interactieve dashboards en een centrale landingspagina oplevert. Het platform verwerkt dagelijks data uit CronosCentral (161 medewerkerrecords, 256 freelancerrecords, 34 voertuigen), TIA (145.980 timesheet-rijen over 11+ jaar) en Salesforce (3.753 records over 6 objecten). De data doorloopt een volledig medallion-traject van Bronze via Silver naar Gold, resulterend in een sterschema met 23 tabellen en een uitgebreide set DAX-measures.

De drie inhoudelijke Power BI rapporten dekken samen de domeinen HR, Operations en Fleet. Ze bieden inzicht in headcount-trends, personeelsverloop, consultantprestaties (billability en utilization), klantconcentratie en het wagenpark. Dynamische subtitels, drillthrough-pagina's en een consistent visueel ontwerp maken de dashboards bruikbaar voor dagelijkse operationele beslissingen. De vier rapporten zijn gebundeld in een Power BI App die als centraal toegangspunt dient voor eindgebruikers.

Daarnaast is het fundament gelegd voor iteratie 2: Salesforce is als derde bronsysteem geïntegreerd in de pipeline, de klantenmapping is geautomatiseerd en de data voor marge- en sales-analyses staat klaar in het lakehouse.

7.2. Evaluatie tegen doelstellingen

Het projectplan formuleerde vier doelstellingen. De eerste (een geïntegreerd dataplatform) is gerealiseerd: drie bronsystemen (CronosCentral, TIA en Salesforce) zijn geïntegreerd via een geautomatiseerde dagelijkse pipeline met kwaliteitsbewaking. De tweede doelstelling, talent matching, is gedeeltelijk gedekt: het dashboard toont per consultant de billability, utilization en klantportfolio, maar er is geen voorspellend model dat consultants automatisch koppelt aan nieuwe opportuniteiten. De derde doelstelling, resource management, is concreet gemaakt via de bench-detectie, het klantconcentratie-overzicht en de consultant ranking op utilization. De vierde doelstelling, operationele wendbaarheid via dagelijkse inzichten, is gerealiseerd door de dagelijkse pipeline-refresh en de interactieve filterstructuur.

Van de 149 oorspronkelijke requirements is 82% van de iteratie 1-scope (HR, Operations, Fleet) gedekt. De Salesforce-integratie in iteratie 2 heeft de klantenmapping en data-pipeline voorbereid. De resterende requirements (loondata, marketing) vereisen bronsystemen die niet beschikbaar waren tijdens de stage.

7.3. Geleerde lessen

Theorie versus praktijk. De drie Microsoft-cursussen (AZ-900, PL-300, DP-600) boden een solide theoretische basis, maar de kloof met de praktijk bleek groter dan verwacht. In de cursussen wordt gewerkt met voorbeelddatasets die schoon, volledig en consistent zijn. In de realiteit begon het project met een GraphQL API die een drieledig authenticatieproces vereiste dat nergens gedocumenteerd stond, en met een urenregistratiesysteem waarin dezelfde persoon onder verschillende namen voorkomt. De cursussen leren hoe een sterschema wordt ontworpen; ze leren niet dat eerst een meerstaps entity resolution nodig hebt voordat je zelfs maar een foreign key kunt leggen.

Datakwaliteit is een continu proces, geen eenmalige stap. Bij aanvang van het project was de verwachting dat de API-data grotendeels correct zou zijn en dat de Silver-laag vooral datatypes en formatting zou corrigeren. In de praktijk bleek datakwaliteit een doorlopend thema. Het veld `DateEmployed` was leeg voor alle 161 medewerkerrecords en moest via de leverancier worden hersteld. Klantnamen kwamen voor in 236 varianten die handmatig moesten worden genormaliseerd. Medewerkers van twee entiteiten (Common Sense AI en Georhythm) ontbraken in TIA vanwege verlopen credentials, een configuratieprobleem dat pas na enige tijd werd geïdentificeerd. Elk van deze problemen vereiste een andere aanpak: communicatie met de leverancier, een regelgebaseerde normalisatieprocedure, of een diepere analyse van de API-structuur.

Meerwaarde van de iteratieve aanpak. De iteratieve aanpak, waarbij na elke sprint een werkend resultaat aan stakeholders wordt getoond, bleek nuttig voor een project als dit. Na de eerste dashboardversie leverde de stagementor concrete feedbackpunten op die de richting van het verdere werk bepaalden: een turnover-KPI met rolling 12-maandenlogica toevoegen, een billability/utilization-toggle implementeren die het hele dashboard dynamisch aanpast, en de utilization-definitie afstemmen met Cronos' eigen berekening. Zonder deze vroegtijdige feedback had het project weken kunnen bouwen aan features die niet aansloten bij de verwachtingen.

Technische beperkingen van Power BI. Een terugkerend patroon tijdens de stage was dat functionaliteit die conceptueel eenvoudig lijkt, in Power BI een creatieve workaround vereist. Conditionele kleuring per segment in een gestapeld staafdiagram werkt niet; de oplossing was aparte measures per kleurband met statische kleurtoewijzing. Elk van deze beperkingen kostte tijd om te ontdekken, te begrijpen en een werkbare oplossing voor te vinden.

Het belang van versiebeheer en documentatie. Door het semantic model in TMDL-formaat te beheren en alle dashboarddefinities als PBIR-JSON in Git op te slaan, was elke wijziging traceerbaar. Dit bleek handig toen measures die via de live MCP-connectie waren aangemaakt, bij een herstart van Power BI Desktop verloren gingen omdat ze alleen bestonden in het draaiende model, niet in de TMDL-bestanden. Hetzelfde principe geldt breder: documentatie die niet wordt bijgehouden, vervalt snel. De discipline om na elke sessie de voortgang, het archief en de weeklog bij te werken heeft ervoor gezorgd dat het project na tien weken nog steeds navigeerbaar is.

Samenwerken in een consultancy-context. Als stagiair bij een consultancybedrijf wordt niet gewerkt in een geïsoleerd ontwikkelteam, maar met stakeholders die elk hun eigen rol en expertise hebben: managing partners, de stagementor, grafische experts, de infrastructuurverantwoordelijke. Het duurt even om te

ontdekken wie expert is in wat, zeker als werktrajectstudent die maar één dag per week op kantoor is. Het is essentieel om proactief vragen te stellen in plaats van aannames te maken, en om de verschillende perspectieven samen te brengen in een coherent product.

AI-ondersteunde ontwikkeling. De tijdsverdeling illustreert de aanpak: 70% van de tijd ging naar ontwerpen en beslissen, 20% naar valideren en testen, en 10% naar het daadwerkelijk genereren van code. De belangrijkste les was dat elke AI-output verificatie vereist. Gegenerateerde DAX-formules konden syntactisch correct maar semantisch fout zijn, PBIR-visuals konden verkeerde databindingen bevatten, en documentatie kon plausibel klinken maar feitelijk niet kloppen. De feedbackloop van ontwerpen, laten genereren, valideren en bijsturen werd de kern van de werkwijze. De tool versnelde de uitvoering, maar het denkwerk en de kwaliteitsbewaking bleven volledig bij de ontwikkelaar.

7.4. Toekomst en aanbevelingen

Het platform is gebouwd met uitbreidbaarheid als uitgangspunt. De medallion-architectuur en het iteratieve model maken het eenvoudig om nieuwe bronsystemen toe te voegen: een ingestie-notebook voor de nieuwe API, Silver-opschoning en een Gold-integratie met het bestaande sterschema.

Concrete aanbevelingen voor vervolg:


- **Salesforce-dashboards:** de pipeline en klantenmapping zijn operationeel (zie hoofdstuk 6). Een opvolger kan hierop een Sales-dashboard bouwen met marge-KPI's per consultant, pipeline-overzichten en budget-versus-besteed analyses. De data en de koppelingen staan klaar.
- **Loondata-integratie** (iteratie 3) maakt exacte margeberekeningen per consultant mogelijk, een prioriteit voor de Managing Partners. De geanonimiseerde Salesforce-tarieven geven al een indicatief beeld.
- **DirectLake-modus:** alle voorbereidingen zijn afgerond. 27 calculated columns zijn verplaatst naar het Gold-notebook (T18) en 5 calculated tables zijn omgezet naar fysieke Delta-tabellen (T19). Het model bevat nu uitsluitend lakehouse-tabellen. De laatste stap is het omschakelen van partition type Import naar DirectLake, wat Fabric capacity vereist.
- **Row-Level Security** moet worden geïmplementeerd zodat elke entiteit uitsluitend eigen data kan zien.

8. Literatuurlijst

- 2sky. (2025). CronosCentral API [Intern document]. Cronos Groep.
- Microsoft. (2025). AZ-900: Microsoft Azure fundamentals. Microsoft Learn. <https://learn.microsoft.com/en-us/credentials/certifications/azure-fundamentals/>
- Microsoft. (2025). DAX function reference. Microsoft Learn. <https://learn.microsoft.com/en-us/dax/>
- Microsoft. (2025). DP-600: Implementing analytics solutions using Microsoft Fabric. Microsoft Learn. <https://learn.microsoft.com/en-us/credentials/certifications/fabric-analytics-engineer-associate/>
- Microsoft. (2025). Microsoft Fabric documentation. Microsoft Learn. <https://learn.microsoft.com/en-us/fabric/>
- Microsoft. (2025). PL-300: Microsoft Power BI data analyst. Microsoft Learn. <https://learn.microsoft.com/en-us/credentials/certifications/power-bi-data-analyst-associate/>
- Microsoft. (2025). Power BI documentation. Microsoft Learn. <https://learn.microsoft.com/en-us/power-bi/>
- Microsoft. (2025). TMDL overview. Microsoft Learn. <https://learn.microsoft.com/en-us/analysis-services/tmdl/tmdl-overview>
- Salesforce. (2025). Salesforce REST API developer guide. Salesforce Developers. https://developer.salesforce.com/docs/atlas.en-us.api_rest.meta/api_rest/
- TIA. (2025). TIA REST API [Intern document]. Cronos Groep.
- togaether. (2025). Data quality checklist [Intern document]. Algorhythm.
- togaether. (2025). Lakehouse richtlijnen [Intern document]. Algorhythm.
- togaether. (2025). Naming conventions [Intern document]. Algorhythm.

9. Bijlagen

9.1. Bijlage A: Sterschema



9.2. Bijlage B: DAX-catalogus

Een DAX-catalogus met alle measures is beschikbaar als digitale bijlage (DAX Catalogus Hawkeye.xlsx). Het bestand bevat per measure: nummer, naam, displayFolder, hidden-status, formule, beschrijving, dependencies en format string.

9.3. Bijlage C: Detailed Design Document


Het Detailed Design Document beschrijft de tabellen, kolommen, datatypes en beschrijvingen van het Gold-sterschema. Dit document is beschikbaar als digitale bijlage (Detailed Design Hawkeye.xlsx).

9.4. Bijlage D: Business glossary

Een business glossary met gebruikte termen is beschikbaar als digitale bijlage (Business Glossary Hawkeye.xlsx). Het bestand bevat per term: definitie, technische bron, domein, drempelwaarden en opmerkingen.

9.5. Bijlage E: Pipelinediagram

Onderstaand diagram toont de volledige datapipeline van bronnen tot rapportage, met de vier Fabric-workspaces en de medallion-lagen.



9.6. Bijlage F: Verklarende woordenlijst

Term	Omschrijving
Billability	Percentage werkuren dat factureerbaar is aan klanten.
DAX	Data Analysis Expressions - de formuletaal van Power BI voor berekeningen en KPI's.
Delta-tabel	Open-source opslagformaat dat transacties, versiebeheer en tijdreizen ondersteunt op grote datasets.
Dimensietabel	Tabel met beschrijvende kenmerken (wie, wat, waar) die context geeft aan metingen.
DirectLake	Power BI-modus waarbij data rechtstreeks uit het lakehouse wordt gelezen zonder importstap.
Drillthrough	Interactiepatroon waarbij een gebruiker doorklikt naar een detailpagina met gefilterde context.
Entity resolution	Proces om records uit verschillende bronnen te koppelen aan dezelfde real-world entiteit.
Feitentabel	Tabel met meetbare gebeurtenissen (uren, aantallen) gekoppeld aan dimensies via sleutels.
Lakehouse	Opslagplatform dat de flexibiliteit van een data lake combineert met de structuur van een data warehouse.
Medallion-architectuur	Ontwerppatroon met drie lagen (Bronze, Silver, Gold) die data stapsgewijs opschonen en verrijken.
Pipeline	Geautomatiseerde keten van stappen die data ophaalt, transformeert en opslaat.
PySpark	Python-interface voor Apache Spark, gebruikt voor gedistribueerde dataverwerking in notebooks.
SCD Type II	Slowly Changing Dimension - techniek om historische wijzigingen bij te houden met begin- en einddatums.
SOQL	Salesforce Object Query Language - querytaal voor het ophalen van data uit Salesforce, vergelijkbaar met SQL.
Semantic model	De gegevenslaag in Power BI die tabellen, relaties en berekeningen definieert voor rapportage.
Sterschema	Datamodelpatroon met een centrale feitentabel omringd door dimensietabellen (star schema).
Surrogate key	Kunstmatige sleutel die records uniek identificeert, onafhankelijk van brondata.
TMDL	Tabular Model Definition Language - tekstformaat voor Power BI semantic models dat versiebeheer in Git mogelijk maakt.
Utilization	Percentage werkuren dat productief besteed is (breder dan billability, inclusief interne projecten).